

金融测评数据交付说明

本次交付新增知识题 203,870 条、文本任务 35,803 条，共 239,673 条。已完成下载、清洗、任务处理和全量程序检查。压缩包包含数据、对应的原始记录、检查结果和处理代码。

文件 / 任务	实际条数
知识与规则	203,870
实体抽取	8,100
事件抽取	8,100
关系抽取	6,303
文本分类	6,700
数值与财务字段	4,000
因果与观点	2,600
合计	239,673

知识题均含题目、完整选项、答案和文字解析。文本的六类任务都有原文和按统一字段整理的答案；因果与观点各 1,300 条。CSV 和 JSONL 是同一批数据的两种格式，不重复计数。

解压后，先看“数据/先看样例.csv”，再看对应任务的 CSV。用 Excel 或 WPS 即可查看。程序读取时用 JSONL，每行是一条数据。

任务	解释	做法
实体抽取	找出公司、股票、市场对象和经济概念。	采用 CFSC 现成标签，核对文字位置，去掉重复标注及明显异常记录。
事件抽取	找出发生了什么、涉及谁、多少股、什么日期。	采用 FEED 原有事件与角色，核对每个角色能否在公告中找到。
关系抽取	写清“谁—什么关系—谁/什么”。	采用 FinCorpus.CN 原三元组，不采用其模型预测字段，剔除缺原文证据等记录。
文本分类	给一篇文字归类；同一篇可以有多个类别。	公告沿用事件类别；处罚文件只从监管认定句提取主题，过滤否定和申辩句。
数值抽取	找出哪个公司的什么指标，是多少，单位是什么，属于哪一年。	从财报标题和正文提取公司、期间、指标、值与单位，用精确小数换算。

任务	解释	做法
因果与观点	因果：为什么、产生什么结果。观点：谁认为、对什么对象、说了什么。	研报中只选明确因果句或明确“我们/本报告”观点句，保留文字证据。

方案采用“现成标注数据+针对原文的处理规则”。前三类已有足量数据，无须从零训练模型；数值、处罚分类、因果和观点没有合适的现成完整答案，已自行处理。

任务	允许使用的标签字段
实体	Corporate=公司；Stock=股票；Market=市场对象；Economy=经济概念。
事件	股权冻结、股份回购、股东减持、股东增持、股权质押；保留每个事件对应的角色。
关系	开展、拥有、位于、合作、投资、属于、应用于。本次未出现“任职于”，不计入实际覆盖。
分类	公告使用上述五个事件相关主题；处罚使用内幕交易、操纵市场、信息披露违法、虚假记载、未勤勉尽责、传播虚假信息。
数值	指标、原数值、原单位、换算值、公司、期间、合并/母公司口径、业务范围、调整条件和原文位置。
因果 / 观点	因果：原因、结果、原文语气、证据。观点：持有人、对象、完整观点、极性、预测时间及证据。

完整字段及事件角色中英对照保存在“数据/标签表.json”。原文未说明的口径、极性和时间填写“未说明”。分类是主题标签；例如质押相关公告也可能讲解除质押。

检查	实测结果
最终数量	知识 203,870；文本 35,803；每个 CSV 与对应 JSONL 条数一致。
逐条原记录核对	全部 239,673 条均能在包内找到下载原始记录；题目、发布者答案、源标签与转换结果已核对。
重复检查	知识按题干和选项归一化去重；六类文本去掉空白和字形差异后跨任务去重。
标注位置	实体、事件角色、关系主客体、金额及因果观点的证据位置逐条检查。
数值换算	万元、亿元、负号、每股单位和百分比按精确小数复算；公司位置和期间字段检查通过。
处理程序	25 项针对易错情况的测试通过。全量检查报告错误数为 0。
数据文件与压缩包	保存文件 SHA-256；最终 ZIP 进行 CRC 校验，检查文件是否损坏。

检查过程中已处理：缺完整选项、重复选项、冲突答案、文字与答案明显不一致、解析依赖外部图片、只有空白解析、乱码、因果长句截断、观点对象混入动词、被合并方利润错归主体、归母/扣非限定词遗漏及标题空格造成的位置偏移。

数量缺口已补齐。文件已明确记录：完成程序检查，但没有通过专业金标验收。“金标”就是经独立确认的标准答案。

实际抽查发现 CFSC 可能漏掉正文中的其他公司名称。因此本包保留原发布者的四类标注，不保证找全每个实体。FEED 采用远程监督，即通过已有信息自动生成标注，并非逐条人工标注；事件角色对应关系、历史与计划状态仍可能有误。关系源标签也未逐条检查专业含义。

数值期间只做到年份或上半年层级；没有恢复原 PDF 页码、完整表格和全部财务字段。业务范围及剔除费用等调整条件另存字段和原文，不能把分业务收入或调整后利润当作公司总收入或原利润。未明确口径的字段写“未说明”。因果记录原文的说法；观点未明确好坏方向时写“未说明”。

知识题保留题库公布答案，不统一视作 2026 年的现行法规答案。七个知识模块由关键词初步分流，版本辨析等类别的覆盖较少。公开数据可能已被模型训练使用；本包尚未划分隐藏测试集，也未完成公司/时间隔离或全面语义去重。

这份成品可用于团队审阅数据、确认标签和运行试验。

来源	实际进入交付的数量	来源说明
FinCorpus	176504 道知识题	发布卡 Apache-2.0
CFLUE（仅知识部分）	27366 道知识题	CC-BY-NC-SA-4.0
CFSC	8,100 条实体任务	未找到独立许可文件
FEED	8,100 条事件+6,500 条公告分类	未找到独立许可文件；远程监督
E-2CNN / FinCorpus.CN	6,303 条关系任务	仓库 MIT
TigerBot 财报	4,000 条数值任务	发布卡 Apache-2.0
TigerBot 研报	2,600 条因果观点任务	发布卡 Apache-2.0
证监会行政处罚	200 条监管分类	官方公开文本；采集截至 2026-10-01

已排除原八大项目及其全部已识别子数据集、镜像和改名版本：ConvFinQA、DocFinQA、FinanceBench、TAT-DQA、MME-Finance、InvestorBench、FinMTEB、FinBen/PIXIU。完整排除清单随包提供。CFLUE 应用部分未使用。

排除按项目及子数据集执行，没有使用已有项目凑数量。

四类来源均有：上市公司公告、年报与财报、金融新闻/研报、监管处罚。监管来源本次只有处罚决定书，没有交易所问询函。CSMAR 公开入口已查看，但没有取得可用数据文件，不计入下载量。

包内数据保留各来源署名和原许可信息，没有把所有来源改成同一许可证。CFLUE 限非商业使用并要求署名、同方式共享。CFSC 和 FEED 许可范围尚不明确，本包尚未公开上传。

官方入口

FinCorpus: <https://huggingface.co/datasets/Duxiaoman-DI/FinCorpus>

CFLUE: <https://github.com/aliyun/cflue>

CFSC: <https://github.com/Ya-dongLi/CFSC>

FEED: <https://github.com/seukgcode/FEED>

FinCorpus. CN: <https://github.com/CGCL-codes/E-2CNN>

财报: <https://huggingface.co/datasets/TigerResearch/tigerbot-earning-plugin>

研报: <https://huggingface.co/datasets/TigerResearch/tigerbot-research-plugin>

处罚: https://www.csrc.gov.cn/csrc/c101928/zfxzgk_zdgk.shtml

例 1：原文“报告期内，公司实现营业收入 2.40 亿元”。标题为鸿泉物联 2022 年年度报告。答案是：公司=鸿泉物联；期间=2022 年；指标=营业收入；原值=2.40 亿元；换算后=240,000,000 元；原文没有明确合并口径，因此口径=未说明。

例 2：原文“1 月份重卡销量大幅度下滑，主要系去年同期销量高位，今年 1 月春节销售淡季，终端需求走弱。”原因是后半句三项；结果是“1 月份重卡销量大幅度下滑”。不能把原因和结果倒过来。

例 3：观点写成“我们认为……”，持有人是报告作者；对象和完整观点从后文提取。没有作者姓名就不编姓名；没有明确看涨看跌就不编正负向。

包内目录	用途
数据	7 类任务的 CSV 和 JSONL、21 条展示样例、标签表。
原始出处	入选数据及解释支持记录对应的下载原记录。不是重新生成的摘要。
检查记录	数量、逐条检查结果、文件哈希和检查中发现的问题。
来源说明	下载地址、版本、原文件哈希、旧项目排除清单及来源 README/许可文件。
复现代码	采集与处理脚本。阅读和交付数据不需要运行这些代码。